

**Universidade do Vale do Itajaí**

PPGCA

## **TRABALHO FINAL**

### **APRENDIZADO PROFUNDO**

**Exploração, Implementação e Avaliação Experimental  
de Modelos de Deep Learning**

**Professor(a):** Felipe Viel

**Período:** 2026/2

Itajaí

2026

# Sumário

|           |                                                                                     |           |
|-----------|-------------------------------------------------------------------------------------|-----------|
| <b>1</b>  | <b>Introdução</b>                                                                   | <b>3</b>  |
| <b>2</b>  | <b>Contextualização</b>                                                             | <b>3</b>  |
| <b>3</b>  | <b>Objetivos</b>                                                                    | <b>4</b>  |
| 3.1       | Objetivo geral . . . . .                                                            | 4         |
| 3.2       | Objetivos específicos . . . . .                                                     | 4         |
| <b>4</b>  | <b>Proposta do Trabalho</b>                                                         | <b>5</b>  |
| <b>5</b>  | <b>Problemas propostos</b>                                                          | <b>5</b>  |
| 5.1       | Problema 1 – Classificação de imagens . . . . .                                     | 5         |
| 5.2       | Problema 2 – Classificação ou regressão de dados tabulares . . . . .                | 6         |
| 5.3       | Problema 3 – Predição e classificação de séries temporais . . . . .                 | 6         |
| 5.4       | Problema 4 – Classificação ou processamento de sequências com Transformer . . . . . | 6         |
| 5.5       | Critério para escolha . . . . .                                                     | 7         |
| <b>6</b>  | <b>Dados</b>                                                                        | <b>7</b>  |
| 6.1       | Datasets públicos . . . . .                                                         | 7         |
| 6.2       | Uso de conjunto de dados próprio . . . . .                                          | 7         |
| 6.3       | Problemas a serem investigados . . . . .                                            | 8         |
| <b>7</b>  | <b>Metodologia Experimental</b>                                                     | <b>8</b>  |
| 7.1       | Análise exploratória . . . . .                                                      | 8         |
| 7.2       | Divisão dos dados . . . . .                                                         | 8         |
| 7.3       | Pré-processamento . . . . .                                                         | 8         |
| 7.4       | Baseline . . . . .                                                                  | 8         |
| 7.5       | Treinamento . . . . .                                                               | 8         |
| 7.6       | Reprodutibilidade . . . . .                                                         | 8         |
| <b>8</b>  | <b>Métricas de Avaliação</b>                                                        | <b>9</b>  |
| 8.1       | Classificação . . . . .                                                             | 9         |
| 8.2       | Regressão . . . . .                                                                 | 9         |
| 8.3       | Séries temporais . . . . .                                                          | 9         |
| 8.4       | Métricas comuns . . . . .                                                           | 9         |
| <b>9</b>  | <b>Plano de Experimentos</b>                                                        | <b>10</b> |
| <b>10</b> | <b>Entregáveis</b>                                                                  | <b>10</b> |
| <b>11</b> | <b>CrITÉRIOS de Avaliação</b>                                                       | <b>11</b> |

|                                        |           |
|----------------------------------------|-----------|
| <b>12 Requisitos Mínimos</b>           | <b>11</b> |
| 12.1 Custo computacional . . . . .     | 12        |
| <b>13 Cronograma Sugerido</b>          | <b>12</b> |
| <b>14 Checklist de Entrega</b>         | <b>12</b> |
| 14.1 Perguntas para reflexão . . . . . | 13        |
| <b>15 Considerações Finais</b>         | <b>13</b> |

# 1 Introdução

O Aprendizado Profundo (*Deep Learning*) é uma área de aprendizado de máquina baseada no uso de redes neurais com múltiplas camadas capazes de aprender representações hierárquicas a partir dos dados. Diferentes arquiteturas foram desenvolvidas para explorar propriedades específicas dos problemas, como relações espaciais em imagens, dependências temporais em sequências e relações entre elementos por meio de mecanismos de atenção.

O trabalho final da disciplina tem como objetivo integrar os conceitos estudados ao longo do semestre em um projeto aplicado. O estudante deverá selecionar um problema, preparar os dados, definir uma arquitetura de rede neural profunda, realizar experimentos e avaliar criticamente os resultados.

A proposta foi planejada para apresentar **nível de dificuldade médio**. Espera-se que o aluno explore aspectos relevantes do modelo, mas sem a necessidade de realizar treinamentos de grande escala. O foco não está apenas em obter a maior métrica possível, mas em compreender as decisões tomadas e analisar experimentalmente seus efeitos.

O projeto deverá responder, de maneira fundamentada, perguntas como: *Qual problema está sendo resolvido? Por que uma determinada arquitetura é adequada? Quais características dos dados influenciam o modelo? Como as escolhas de hiperparâmetros afetam o desempenho? Quais são as limitações da solução?*

# 2 Contextualização

A escolha da arquitetura é uma etapa fundamental em projetos de Aprendizado Profundo. Redes densas são adequadas para vetores de características e dados tabulares; redes convolucionais exploram relações locais e espaciais; redes residuais facilitam o treinamento de modelos mais profundos; redes recorrentes são capazes de modelar dependências em sequências; e Transformers utilizam mecanismos de atenção para modelar relações entre elementos de uma entrada.

Tabela 1: Relação entre tipos de dados, problemas e arquiteturas.

| Arquitetura  | Aplicações típicas                         | Aspectos a explorar                                            |
|--------------|--------------------------------------------|----------------------------------------------------------------|
| DNN/MLP      | Dados tabulares, classificação e regressão | profundidade, largura, ativação, regularização                 |
| CNN          | Imagens e dados com estrutura espacial     | filtros, pooling, kernel, augmentation                         |
| ResNet       | Visão computacional                        | conexões residuais, profundidade, transferência de aprendizado |
| RNN/LSTM/GRU | Séries temporais e sequências              | janela temporal, unidades, camadas e memória                   |
| Transformer  | Texto, sequências e séries temporais       | atenção, heads, embedding e blocos                             |

O estudante deverá relacionar a arquitetura escolhida às características do problema, discutindo vantagens, limitações e custo computacional.

## 3 Objetivos

### 3.1 Objetivo geral

Desenvolver, treinar e avaliar uma solução baseada em Aprendizado Profundo para um problema aplicado, explorando uma arquitetura compatível com os dados e realizando uma análise experimental das principais decisões de modelagem.

### 3.2 Objetivos específicos

1. Formular claramente o problema e definir a variável-alvo.
2. Selecionar ou construir um conjunto de dados adequado.
3. Realizar análise exploratória dos dados.
4. Identificar problemas de qualidade, distribuição ou representação.
5. Realizar pré-processamento de maneira adequada e reprodutível.
6. Selecionar e justificar uma arquitetura de Deep Learning.
7. Implementar e treinar o modelo.
8. Estabelecer uma configuração inicial (*baseline*).

9. Explorar pelo menos duas alterações de arquitetura ou hiperparâmetros.
10. Avaliar o modelo utilizando métricas apropriadas.
11. Comparar experimentalmente as configurações.
12. Discutir resultados, limitações e possibilidades de melhoria.

## 4 Proposta do Trabalho

Cada aluno ou grupo deverá escolher **um dos quatro problemas** apresentados na Seção 5. Também será permitida a proposição de um problema próprio, desde que aprovado previamente pelo professor.

O projeto deverá contemplar: definição do problema; escolha e caracterização dos dados; análise exploratória; preparação dos dados; escolha da arquitetura; definição do *baseline*; treinamento; experimentação; avaliação; análise crítica; documentação e apresentação.

A atividade deverá demonstrar **processo experimental**, e não apenas a execução de um código pronto. O aluno deverá formular hipóteses, modificar variáveis de interesse, observar os resultados e justificar suas conclusões.

## 5 Problemas propostos

São propostas quatro modalidades de projeto, selecionadas para permitir o uso de arquiteturas diferentes e manter o custo computacional em nível compatível com uma disciplina.

### 5.1 Problema 1 – Classificação de imagens

**Objetivo:** desenvolver um modelo capaz de atribuir uma classe a uma imagem.

**Arquiteturas sugeridas:** CNN própria; CNN com *Batch Normalization* e *Dropout*; ResNet-18 ou ResNet-34; transferência de aprendizado com rede residual de pequeno porte.

**Datasets sugeridos:** EuroSAT; Intel Image Classification; Oxford-IIIT Pet.

**Desafios:** variação de iluminação, escala e orientação; classes desbalanceadas; quantidade limitada de exemplos; sobreajuste; escolha de *data augmentation*.

**Experimentos:** CNN simples versus ResNet; diferentes filtros; *learning rate*; *Dropout*; estratégias de *augmentation*.

## 5.2 Problema 2 – Classificação ou regressão de dados tabulares

**Objetivo:** utilizar uma rede neural profunda para classificação ou regressão em dados tabulares.

**Arquiteturas sugeridas:** MLP com duas a cinco camadas; diferentes ativações; *Batch Normalization*; *Dropout*.

**Datasets sugeridos:** UCI Adult; UCI Wine Quality; UCI Breast Cancer Wisconsin; California Housing; UCI Bank Marketing.

**Desafios:** atributos categóricos e numéricos, valores ausentes, escalas distintas, desbalanceamento, atributos redundantes e sobreajuste.

**Experimentos:** variar profundidade e largura; comparar ativações; testar normalização; modificar *Dropout*; avaliar balanceamento.

## 5.3 Problema 3 – Predição e classificação de séries temporais

**Objetivo:** desenvolver um modelo para previsão ou classificação a partir de dados sequenciais.

**Arquiteturas sugeridas:** RNN; LSTM; GRU; LSTM/GRU empilhada.

**Datasets sugeridos:** Jena Climate; Household Electric Power Consumption; UCI Human Activity Recognition; FordA/FordB; Air Passengers.

**Desafios:** dependência temporal, tendência, sazonalidade, ruído, escolha da janela, normalização e vazamento temporal.

**Experimentos:** RNN versus LSTM versus GRU; diferentes janelas; unidades; camadas; *Dropout*; horizontes de previsão.

## 5.4 Problema 4 – Classificação ou processamento de sequências com Transformer

**Objetivo:** utilizar um Transformer de pequeno porte para resolver um problema envolvendo sequências.

**Arquiteturas sugeridas:** Transformer Encoder; Transformer para classificação; uma ou duas camadas de encoder; CNN–Transformer ou RNN–Transformer.

**Datasets sugeridos:** IMDB; AG News; UCI Human Activity Recognition; FordA/FordB; Jena Climate.

**Desafios:** representação das entradas, embeddings, tamanho das sequências, custo da atenção e sobreajuste.

**Experimentos:** número de *attention heads*; dimensão do embedding; número de blocos; tamanho da sequência; comparação com LSTM ou CNN.

## 5.5 Critério para escolha

O aluno deverá justificar a arquitetura considerando tipo de dado, estrutura espacial ou temporal, tamanho do conjunto, complexidade, custo computacional e referências técnicas.

# 6 Dados

## 6.1 Datasets públicos

Tabela 2: Datasets sugeridos.

| Dataset            | Tipo       | Tarefa                  | Arquiteturas                |
|--------------------|------------|-------------------------|-----------------------------|
| EuroSAT            | Imagens    | Classificação           | CNN, ResNet                 |
| UCI Adult          | Tabular    | Classificação           | DNN/MLP                     |
| Wine Quality       | Tabular    | Classificação/regressão | DNN/MLP                     |
| California Housing | Tabular    | Regressão               | DNN/MLP                     |
| Jena Climate       | Temporal   | Previsão                | RNN, LSTM, GRU, Transformer |
| HAR                | Sequencial | Classificação           | RNN, LSTM, GRU, Transformer |
| FordA              | Temporal   | Classificação           | RNN, CNN, Transformer       |
| IMDB               | Texto      | Classificação           | RNN, LSTM, Transformer      |
| AG News            | Texto      | Classificação           | Transformer                 |

Os datasets podem ser obtidos em repositórios públicos, como UCI Machine Learning Repository, TensorFlow Datasets, Kaggle ou pelas bibliotecas de aprendizado de máquina. A fonte utilizada deverá ser registrada no relatório.

## 6.2 Uso de conjunto de dados próprio

Será permitida a utilização de conjunto próprio, desde que aprovado pelo professor. Deverão ser apresentados origem, coleta, número de amostras, variável-alvo, formato, rotulagem, limitações e questões de privacidade.

### 6.3 Problemas a serem investigados

O aluno deverá identificar os problemas relevantes ao seu conjunto: valores ausentes, ruído, *outliers*, duplicatas, desbalanceamento, dados insuficientes, escalas diferentes, distribuição inadequada, *data leakage*, correlação temporal, resolução e sobreajuste.

## 7 Metodologia Experimental

### 7.1 Análise exploratória

Antes do treinamento, o aluno deverá caracterizar os dados por estatísticas, gráficos e análises pertinentes, como distribuição das classes, exemplos de imagens, variáveis, séries e comprimento de sequências.

### 7.2 Divisão dos dados

Deverá ser utilizada separação adequada entre treinamento, validação e teste. Como referência, 70/15/15 ou 80/10/10. Em séries temporais, a divisão deverá respeitar a ordem temporal.

### 7.3 Pré-processamento

Poderão ser utilizados normalização, padronização, codificação de categorias, redimensionamento, *data augmentation*, janelas temporais, tokenização e padding. É obrigatório evitar *data leakage*.

### 7.4 Baseline

O primeiro modelo será o *baseline*. Ele deverá ser simples o suficiente para servir de referência às demais configurações.

### 7.5 Treinamento

Recomenda-se *Early Stopping*. Deverão ser registrados, quando pertinentes, função de perda, otimizador, *learning rate*, *batch size*, épocas, critério de parada e número de parâmetros.

### 7.6 Reprodutibilidade

Recomenda-se fixar sementes aleatórias e registrar versões relevantes das bibliotecas.

## 8 Métricas de Avaliação

As métricas devem ser escolhidas de acordo com o problema.

### 8.1 Classificação

Accuracy, Precision, Recall, F1-score, matriz de confusão, ROC-AUC e PR-AUC poderão ser utilizadas. Em problemas desbalanceados, Accuracy isoladamente não será suficiente.

### 8.2 Regressão

MAE, MSE, RMSE e  $R^2$  poderão ser utilizadas.

### 8.3 Séries temporais

Recomenda-se MAE e RMSE, acompanhados de gráficos de valores reais versus previstos. MAPE poderá ser utilizado quando apropriado.

### 8.4 Métricas comuns

$$OverallAccuracy = \frac{N_{corretas}}{N_{total}} \quad (1)$$

$$AverageAccuracy = \frac{1}{C} \sum_{i=1}^C \frac{n_{ii}}{N_i} \quad (2)$$

$$Precision = \frac{TP}{TP + FP} \quad (3)$$

$$Recall = \frac{TP}{TP + FN} \quad (4)$$

$$F1 = 2 \frac{Precision \cdot Recall}{Precision + Recall} \quad (5)$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (6)$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (7)$$

Não será definida uma acurácia mínima universal. O aluno deverá estabelecer um baseline, definir hipóteses, demonstrar mudanças mensuráveis e explicar resultados positivos e negativos.

## 9 Plano de Experimentos

Cada projeto deverá apresentar pelo menos **três configurações**: um baseline e pelo menos duas variações.

Tabela 3: Planejamento experimental.

| Exp. | Configuração        | Variável alterada | Hipótese               |
|------|---------------------|-------------------|------------------------|
| E1   | Baseline            | –                 | Estabelecer referência |
| E2   | Modelo modificado   | Hiperparâm/arq    | Avaliar efeito         |
| E3   | Segunda modificação | Hiperparâmo/arq   | Testar hipótese        |

Podem ser alterados número de camadas, filtros, unidades recorrentes, *attention heads*, embedding, *learning rate*, *batch size*, *Dropout*, *Batch Normalization*, *data augmentation* e tamanho de janela.

Tabela 4: Modelo de tabela de resultados.

| Exp. | Parâmetros | Épocas | Métrica 1 | Métrica 2 | Observação  |
|------|------------|--------|-----------|-----------|-------------|
| E1   | –          | –      | –         | –         | Baseline    |
| E2   | –          | –      | –         | –         | Alteração 1 |
| E3   | –          | –      | –         | –         | Alteração 2 |

## 10 Entregáveis

O projeto deverá resultar em código-fonte, notebook ou scripts, relatório técnico e apresentação.

O relatório deverá conter: Introdução; Contextualização; Definição do problema; Dataset; Análise exploratória; Pré-processamento; Arquitetura; Metodologia; Experimentos; Resultados; Discussão; Limitações; Conclusão; Referências.

A apresentação deverá possuir aproximadamente 10 a 15 minutos por grupo e destacar problema, dados, arquitetura, experimentos, métricas, resultados e conclusões. O grupo deverá estar preparado para explicar as decisões e principais partes do código.

## 11 Critérios de Avaliação

Tabela 5: Rubrica sugerida.

| <b>Critério</b>                            | <b>Peso</b> |
|--------------------------------------------|-------------|
| Definição e contextualização do problema   | 10%         |
| Análise e preparação dos dados             | 15%         |
| Implementação e compreensão da arquitetura | 20%         |
| Exploração experimental e hiperparâmetros  | 20%         |
| Avaliação e análise dos resultados         | 20%         |
| Relatório e apresentação                   | 10%         |
| Organização e reprodutibilidade do código  | 5%          |
| <b>Total</b>                               | <b>100%</b> |

Serão valorizados coerência entre problema, dados e arquitetura; justificativa técnica; qualidade do tratamento dos dados; experimentos controlados; análise crítica; clareza e reprodutibilidade.

## 12 Requisitos Mínimos

1. Problema claramente definido.
2. Dataset documentado e fonte registrada.
3. Análise exploratória.
4. Problemas dos dados identificados.
5. Pré-processamento documentado.
6. Divisão treino/validação/teste.
7. Arquitetura justificada.
8. Baseline.
9. Pelo menos três configurações experimentais.
10. Histórico de treinamento.
11. Métricas apropriadas.
12. Comparação dos experimentos.

13. Limitações discutidas.
14. Código organizado.
15. Relatório e apresentação.

## 12.1 Custo computacional

Recomenda-se utilizar modelos pequenos ou médios, número limitado de épocas, *Early Stopping*, redução de resolução quando justificável e subconjuntos quando o dataset completo for excessivo. Deve-se evitar treinamento do zero de modelos de grande escala.

## 13 Cronograma Sugerido

Tabela 6: Cronograma de referência.

| Etapa | Atividade             | Produto                  |
|-------|-----------------------|--------------------------|
| 1     | Definição do problema | Problema e objetivo      |
| 2     | Seleção dos dados     | Dataset definido         |
| 3     | Análise exploratória  | Diagnóstico dos dados    |
| 4     | Pré-processamento     | Pipeline de dados        |
| 5     | Baseline              | Primeiro modelo          |
| 6     | Experimentos          | Configurações comparadas |
| 7     | Avaliação             | Resultados e discussão   |
| 8     | Finalização           | Relatório e apresentação |

## 14 Checklist de Entrega

- ☐ Problema claramente definido.
- ☐ Motivação apresentada.
- ☐ Dataset descrito e fonte registrada.
- ☐ Análise exploratória realizada.
- ☐ Problemas dos dados identificados.
- ☐ Pré-processamento documentado.
- ☐ Divisão treino/validação/teste definida.
- ☐ Arquitetura justificada.

- ☐ Baseline implementado.
- ☐ Pelo menos duas variações experimentais.
- ☐ Histórico de treinamento apresentado.
- ☐ Métricas apropriadas utilizadas.
- ☐ Resultados comparados em tabela e/ou gráfico.
- ☐ Limitações discutidas.
- ☐ Código organizado.
- ☐ Relatório finalizado.
- ☐ Apresentação preparada.

### 14.1 Perguntas para reflexão

1. Por que esta arquitetura foi escolhida?
2. Qual característica dos dados mais influencia o problema?
3. Qual foi a principal dificuldade?
4. Qual alteração experimental produziu maior impacto?
5. Houve sobreajuste? Como foi identificado?
6. A métrica escolhida representa adequadamente o objetivo?
7. O modelo generaliza para dados não vistos?
8. O que seria necessário para melhorar o sistema?

## 15 Considerações Finais

O trabalho final deverá representar a integração dos principais conceitos da disciplina de Aprendizado Profundo, equilibrando aplicação prática, exploração de arquiteturas e análise experimental.

O desempenho quantitativo é importante, mas não constitui o único critério de qualidade. Um trabalho com desempenho moderado, porém baseado em metodologia correta, experimentos bem planejados e análise crítica consistente, poderá apresentar maior valor acadêmico do que uma solução que apenas utilize uma arquitetura sofisticada sem compreender seus resultados.

Como princípio geral, o aluno deverá demonstrar que consegue percorrer o ciclo completo de um projeto de Deep Learning:

**problema → dados → modelo → treinamento → avaliação → análise.**